

RETAILPRO

Análisis de Ventas y Operaciones

De 34.500 transacciones crudas a un modelo dimensional, consultas SQL y un dashboard que revela dónde el negocio pierde dinero — y qué hacer al respecto.

PostgreSQL

Python

Power Query

DAX

Power BI

Micaela Puebla

Data Analyst

[linkedin.com/in/micaela-puebla](https://www.linkedin.com/in/micaela-puebla) · pueblamicaela00@gmail.com

\$5,87M

ingresos analizados · 25 meses

La pregunta de negocio

PREGUNTA CENTRAL

¿Dónde está el negocio dejando de ganar dinero, y qué decisiones operativas pueden corregirlo?

RetailPro es un e-commerce multicategoría con dos años de operación. La dirección tiene los datos de ventas, pero no una lectura clara de su rentabilidad real ni de su desempeño operativo. El objetivo es transformar esas transacciones en decisiones concretas.

01

Rentabilidad

¿Todas las ventas dejan margen, o hay operaciones que pierden plata?

02

Concentración

¿De qué categorías y regiones depende realmente el ingreso?

03

Operación

¿Cómo se comportan las entregas y las devoluciones?

De una tabla plana a un modelo dimensional

Dataset público E-commerce Sales Transactions (Kaggle) · 34.500 transacciones · período 2023–2025. Origen sintético, tratado como caso real: no se inventó ningún dato ni nombre de cliente.

Tabla	Registros	Rol	Columnas clave
F_ventas	34.500	Hechos	orden_id (PK), cliente_id (FK), producto_id (FK), fecha_compra (FK), total_venta, margen, devuelto...
D_clientes	7.903	Dimensión	cliente_id (PK), edad, genero, region
D_productos	24.912	Dimensión	producto_id (PK), categoria, precio_unitario
D_fecha	761 días	Calendario	fecha (PK), Año, Mes, AñoMes — generada en Power Query

REGLA DE LIMPIEZA (SCD tipo 1 — a defender ante el evaluador)

Los IDs no son claves estables: un mismo cliente/producto aparece con atributos contradictorios entre filas. Cada dimensión toma el valor de la transacción más reciente ("la más reciente gana"). El dataset identifica a los clientes por ID —no trae nombre—; no se fabricaron nombres.

Los conceptos, aplicados al caso

01 · DATOS VS. INFORMACIÓN

Un dato es un hecho crudo (margen = -2,68). La información nace al procesarlo con contexto: "el 49% de las órdenes <\$25 dan margen negativo". Se decide sobre información, no sobre filas sueltas.

02 · SUBLENGUAJES DE SQL

DDL (CREATE) · DML (SELECT) · DCL (GRANT) · TCL (COMMIT). El CREATE TABLE del modelo es DDL; la consulta de los últimos 30 días es DML.

03 · IA EN EL ANÁLISIS





Acelera y amplía: detecta patrones, predice, procesa texto (NLP) y asiste en SQL/DAX. Caso aplicado: predecir si una orden dará margen negativo antes de despacharla.

04 · STORYTELLING CON DATOS

Narrativa que lleva a una decisión: contexto → hallazgo → recomendación. Un mensaje por visual, títulos que dicen la conclusión y honestidad con los datos parciales.



Exploración inicial en Python

Exploración en pandas + matplotlib. Los títulos de cada gráfico son la conclusión, no el eje.




Transformación y limpieza en Power Query


- Conexión directa a PostgreSQL (Importar) para evitar el bug de separador decimal del locale es-AR.
- Fijar tipos por columna y convertir devuelto a lógico.
- Columnas derivadas: AñoMes, MargenNegativo, RangoTicket.
- Tabla de calendario D_fecha creada con código M.



El esquema estrella y la consulta obligatoria




Modelo dimensional (esquema estrella) — D_clientes 1:N F_ventas · D_productos 1:N F_ventas · D_fecha 1:N F_ventas



Consulta Ej1 · últimos 30 días (ventana dinámica, sin fechas hardcoded): 1.539 filas · \$259.388,45. Tipos con criterio (DATE, DECIMAL, BOOLEAN) · carga verificada 7.903 / 24.912 / 34.500.

Un panel, una decisión



Apertura

Ingresos estables mes a mes: negocio sólido y recurrente.

Ingreso

Electronics concentra el 45% de los ingresos.

Pérdida

Cuanto más pequeña la compra, mayor la pérdida.

Operación

Fashion y Electronics con mayor tasa de devolución.

Cómo sé que los números cierran

CHECKPOINT SQL ↔ DAX

\$259.388 = **\$259.388**

consulta SQL 30 días

medida DAX

La ventana dinámica de 30 días da el mismo total (1.539 órdenes) en PostgreSQL y en Power BI. Si el número coincide en las dos herramientas, el modelo y las relaciones están bien contruidos.

7.903 · 24.912 · 34.500

Conteo de filas verificado — sin filas perdidas en el ETL.

Tipos con criterio

DATE para filtrar por tiempo, DECIMAL para dinero, BOOLEAN para devuelto — no todo texto.

Honestidad

Los meses parciales (sep-2023 y sep-2025) se marcan para no leer su caída como una baja real.

Del dato a la decisión

HALLAZGO PRINCIPAL

1 de cada 6 órdenes pierde dinero

El 17,7% de las órdenes tiene margen negativo, y el driver no es el descuento sino el ticket chico: el 49,2% de las órdenes menores a \$25 pierden plata, contra el 0% de las mayores a \$100.

RECOMENDACIÓN

Establecer un mínimo de compra o un umbral de envío pago por debajo de cierto monto.

45%

Electronics domina el ingreso — categoría crítica: priorizar disponibilidad de stock.

7,7%

Fashion se devuelve por encima de la media — revisar descripciones y guía de talles.

Ciclo completo

Del dato crudo al modelo dimensional, SQL, Power Query, DAX y un dashboard con recomendación de negocio.

RETAILPRO

Muchas gracias por **tu tiempo**

Si necesitas que alguien convierta tus datos en decisiones, escíbeme.

Micaela Puebla

Data Analyst

[linkedin.com/in/micaela-puebla](https://www.linkedin.com/in/micaela-puebla) · pueblamicaela00@gmail.com